
CHAPITRE 1

INTRODUCTION

1.1 Qu'est ce que l'analyse des données ?

L'analyse des données est une technique relativement récente (1960-1970). Elle est la forme moderne de la statistique descriptive.

Par rapport à la statistique qui consiste à formaliser l'induction, à étudier un seul caractère mesuré sur un petit ensemble d'individus, à développer les notions d'estimation et de test fondé sur des hypothèses très restrictives, l'analyse des données vise à décrire, à réduire et à classer des observations en s'appuyant sur un outil mathématique. Elle vise donc à mettre en œuvre des techniques d'analyse sans faire aucune hypothèse sur les phénomènes observés tout en permettant une étude globale des caractères (liaisons entre caractères quantitatifs et/ou qualitatifs, ressemblance, différence, ...).

1.2 Informatique et Analyse des données

L'ordinateur et l'analyse des données sont apparus presque en même temps. Les méthodes d'analyse des données ont été élaborées depuis fort longtemps (par exemple vers 1930 Hotelling posait le fondement de l'ACP ou Analyse en Composantes Principales en développant les travaux de Spearman et de Pearson qui dataient du début du siècle). Jusqu'aux années 1960, celles-ci étaient perfectionnées et s'enrichissaient de variantes mais toutes restaient inabordables à cause des masses considérables de calcul. C'est l'apparition de l'ordinateur qui permirent la vulgarisation des techniques de l'analyse des données.

1.3 Démarche de l'analyse des données

La démarche de l'analyse des données consiste à ne présenter que les faits bruts, mais en ayant soin de les examiner sous un angle tel que les tendances apparaîtront d'elles-mêmes pour que l'utilisateur puisse trouver des explications aux faits et d'en tirer des conséquences ou des principes d'actions.

1.4 Les différents types de tableaux de données

1.4.1 Tableau individus $\times$ caractères quantitatifs

Individus	X_1	X_2	$\dots$	X_j	$\dots$	X_k
1				$\vdots$		
2				$\vdots$		
$\vdots$				$\vdots$		
i	$\dots$	$\dots$	$\dots$	x_{ij}		
$\vdots$						
n						

Exemple : Relevé de notes

1.4.2 Tableau de contingence

Un tableau de contingence donne la répartition d'une population statistique suivant deux caractères qualitatifs éclatés chacun en modalités exhaustives et exclusives les unes des autres.

	Mod_{21}	Mod_{22}	$\dots$	Mod_{2j}	$\dots$	Mod_{2l}
Mod_{11}				$\vdots$		
Mod_{12}				$\vdots$		
$\vdots$				$\vdots$		
Mod_{1i}	$\dots$	$\dots$	$\dots$	n_{ij}		
$\vdots$						
Mod_{1k}						

où n_{ij} est le nombre d'individus possédant la modalité i du premier caractère et la modalité j du deuxième caractère.

Exemple : Répartition de l'ensemble des enseignants suivant leurs grades et leurs universités d'affectation.

1.4.3 Tableau logique et tableau disjonctif complet

Dans les tableaux logiques, chaque individu appartient à un groupe particulier et à un seul.

	1	2	$\dots$	j	$\dots$	p
1				$\vdots$		
2				$\vdots$		
$\vdots$				$\vdots$		
i	$\dots$	$\dots$	$\dots$	x_{ij}		
$\vdots$						
n						

où $x_{ij} = 1$ si l'individu i appartient au groupe j et 0 autrement. Dans chaque ligne, un terme et un seul est égal à 1.

Un tableau disjonctif complet est formé par la juxtaposition de plusieurs tableaux logiques.

Exemple : Tableau des étudiants par classe, par sexe, par type de résidence et résultat en fin d'année.

1.4.4 Tableau de données ordinales

Ils sont souvent utilisés en techniques commerciales ou en général, là où une réponse donnée sous forme d'un classement apporte une information plus cohérente.

	1	2	...	i	...	p
1				$\vdots$		
2				$\vdots$		
$\vdots$				$\vdots$		
i	...	...	...	x_{ij}		
$\vdots$						
n						

$$\forall j \in J, \forall j' \in J, \forall i \in I, j \neq j' \Rightarrow x_{ij} \neq x_{ij'} \text{ et } 1 \leq x_{ij} \leq p$$

$$\text{Notons que } \sum_{k=1}^p x_{ik} = \frac{p(p+1)}{2}$$

1.4.5 Tableau de distance, de proximités

En statistique, pour une population statistique I , on appelle :

- Indice de distance : une fonction symétrique à valeurs réelles et positives entre 2 individus ; plus ces 2 individus se "ressemblent", plus la valeur de cet indice est faible.

$$\forall i \in I, \forall i' \in I, \quad d(i, i') = d(i', i) \quad \text{et} \quad d(i, i) = 0$$

- indice de proximité : une fonction à valeurs réelles définie entre 2 individus et symétrique ; plus ces 2 individus se "ressemblent", plus la valeur de l'indice est élevée.

Notons que :

- L'indice de distance peut être déduit de l'indice de proximité et réciproquement.
- Souvent, on choisit un indice de proximité compris entre -1 et $+1$ par analogie avec le coefficient de corrélation.
- Les tableaux de distances (ou de proximités) sont souvent présentés par une matrice symétrique définie positive de diagonale nulle.

1.4.6 Tableaux mixtes

Ce sont des tableaux de données multidimensionnelles dans lesquels les variables sont de natures différentes : il s'agit en général d'un mélange de variables qualitatives et quantitatives.

1.5 Les différentes techniques de l'A.D.

1. La régression : basée sur le principe des droites ou des plans des moindres carrés se fauflant aux mieux à travers un nuage de points.
2. L'analyse des variances pour tester l'hypothèse d'égalité des moyennes (hypothèse nulle) de plusieurs échantillons issus d'une population.
3. Les analyses factorielles, dont les plus classiques et les plus utilisées sont :
 - Analyse en Composantes Principales (ACP) : basée sur l'étude de la covariance ou de la corrélation entre les variables, elle peut être utilisée sur des tableaux individus x caractères quantitatifs.
 - Analyse Factorielle des Correspondances (AFC) : basée sur une décomposition du χ^2 de contingence, elle permet d'étudier la dépendance de 2 caractères qualitatifs.
 - Analyse Factorielle Discriminante (AFD) : qui permet d'expliquer, au sens de la régression, une variable qualitative par des caractères quantitatifs.
 - Analyse Factorielle de Correspondance Multiple (AFCM) : qui est une généralisation de l'AFC, elle permet d'étudier la correspondance de plus de 2 caractères qualitatifs.
4. Les méthodes de classification numérique ou typologie ou taxinomie qui consistent à regrouper les individus en un groupe restreint de classes homogènes.

Nous verrons successivement dans les chapitres suivants ces principales techniques d'Analyse des Données. Elles sont toutes programmables sur micro-ordinateurs.

CHAPITRE 2

RÉGRESSION

2.1 Problématique

Etant donné n observations sur lesquels on mesure deux caractères quantitatifs X et Y , comment peut-on trouver une courbe d'équation $Y = f(X)$ qui nous donne la relation exacte entre ces deux caractères. X est appelé variable explicative tandis que Y est la variable à expliquer.

Nous verrons dans ce chapitre quatre types de régression :

- la régression simple,
- la régression polynomiale,
- la régression multiple,
- la régression pas à pas (ou par étape).

2.2 Régression simple

C'est le cas où il n'y a qu'une variable explicative pour une variable à expliquer.

2.2.1 Objectif

L'idée consiste à trouver la droite des moindres carrés la plus proche du nuage des points formés par les couples (x_i, y_i) observés sur les deux variables X et Y . Il est clair que trouver cette relation exacte est très difficile, voire impossible. La technique de régression se contente de trouver l'équation d'une courbe de la forme : $y = f(x) + e$ qui serait la plus proche possible du réel. e désigne l'effet secondaire (ou erreur ou résidu) indépendant de la variable X et suit une loi normale centrée et réduite.

2.2.2 Corrélation simple

On cherche à tracer la droite des moindres carrés à travers le nuage des n points (x_i, y_i) . L'équation de cette droite est de la forme :

$$Y = aX + b \quad \text{où } y_i = ax_i + b + e_i \quad \text{pour } i = 1..n$$

Hypothèses :

- Les e_i sont indépendants des x_i
- La variance des erreurs est constante.

Les coefficients a et b de la droite se calcule comme suit :

$$a = \frac{Cov(X, Y)}{V(X)} \quad \text{et} \quad b = \bar{y} - a\bar{x}$$

Le coefficient de corrélation montre le rapport entre les deux variables X et Y . Il mesure la qualité de la liaison qui existe entre elles et par conséquent la fiabilité de la régression :

$$R = \frac{Cov(X, Y)}{\sqrt{V(X)V(Y)}} \quad \text{ou} \quad R = \frac{Cov(X, Y)}{\sigma_X \sigma_Y}$$

Remarques :

1. Sa valeur se situe entre -1 et 1
2. Si $R = 1$ ou $R = -1$, tous les points sont sur la droite de régression.
3. Plus la valeur de R s'éloigne de -1 et 1, moins les points concernés sont concentrés autour de la ligne (corrélation moins fiable)
4. En fait, la fiabilité est mesurée par le coefficient de détermination $D = R^2$
5. Si $R < 0$, on parle de corrélation négative alors Y est inversement proportionnel à X
6. Si $R > 0$, on parle de corrélation positive alors Y est en proportion de X

On ajoute souvent à tous ces coefficients le coefficient d'erreur standard, note SE, qui caractérise l'écart entre le modèle obtenu par la régression et l'observation.

2.2.3 Exemple

Prix des appartements expliqués par leurs surfaces.

2.3 La régression polynomiale

C'est une amélioration de la régression simple. Le modèle est construit à l'aide d'un polynôme au lieu de la droite des moindres carrés. Le but est donc d'ajuster les n observations sur les deux variables (x_i, y_i) à un polynôme de degré d quelconque. Ce polynôme n'est pas forcément linéaire. En pratique, on propose quatre modes de régression polynomiale.

Mode de régression	Modèle
Linéaire-linéaire	$y = \sum_{i=1}^{d+1} \beta_i x^{i-1}$
Logarithmique-linéaire	$y = e^{\sum_{i=1}^{d+1} \beta_i x^{i-1}}$
Linéaire-logarithmique	$y = \sum_{i=1}^{d+1} \beta_i (\log x)^{i-1}$
Logarithmique-logarithmique	$y = e^{\sum_{i=1}^{d+1} \beta_i (\log x)^{i-1}}$

Pour chacun de ces quatre types de régression, on envisage trois modes d'erreurs sur la mesure de y_i .

mode 0 : mesure sans erreur

mode 1 : erreur d'origine statistique $y = \pm\sqrt{y_i}$

mode 2 : erreur expérimentale σ_j (=écart-type)

Le polynôme résultat est défini par les coefficients β_i .

2.4 Régression multiple

En régression simple, il n'y a qu'une variable explicative X pour une variable à expliquer Y et on a la droite des moindres carrés à travers le nuage de n points correspondant aux n observations dont on dispose. En régression multiple, on généralise le procédé : avec 2 variables explicatives X_1 et X_2 , on a un nuage dans l'espace à trois dimensions et un plan des moindres carrés à tracer au mieux à travers ce nuage. Au-delà de 2 variables, il faudrait parler d'hyperplan, ..., mais ces images géométriques n'apportent pas grand chose à la compréhension : s'il y a k variables explicatives $X_1, X_2, \dots, X_k$, il faut trouver k coefficients $A_1, A_2, \dots, A_k$, plus un terme constant y_0 de façon à bâtir la relation :

$$y = y_0 + A_1X_1 + A_2X_2 + \dots + A_kX_k$$

qui se rapproche le plus possible de la réalité des n observations et qu'on appelle équation de régression. Nous supposons bien entendu qu'il y a plus d'observations que de variables explicatives et même assez nettement plus pour que le calcul ait un sens. On a donc $n > k$. Les quantités $A_1, A_2, \dots, A_k$, qu'il s'agit de trouver sont les coefficients. Ils forment un vecteur colonne A . Les n valeurs de Y forment également un vecteur colonne Y tandis que les $X_1, X_2, \dots, X_k$ forment une matrice $X(n, k)$. y_0 s'appelle le terme constant.

2.4.1 Calcul des coefficients

Le vecteur A des coefficients est donné par la formule suivante :

$$A = (X'X)^{-1}(X'Y)$$

laquelle peut s'entendre de 2 manières différentes conduisant à 2 méthodes de calcul distinctes :

1. La première méthode utilise des variables centrées, c'est-à-dire que la première opération consiste à transposer l'origine des coordonnées au centre de gravité du nuage. En d'autres termes, on calcule pour toutes les variables $Y, X_1, X_2, \dots, X_k$ une valeur moyenne sur les n observations et on mesure chacune d'entre elles par rapport à cette moyenne (en plus ou en moins avec le signe correspondant).

Dans ces conditions, la matrice X est de dimensions (n, k) et le produit $X'X$ de dimensions (k, k) est symétrique (matrice d'inertie). Ce calcul fournit les k valeurs $A_1, A_2, \dots, A_k$, mais ne fournit pas le terme constant y_0 qu'il faut calculer à part, ce qui se fait très facilement en écrivant que l'hyperplan des moindres carrés passe par le centre de gravité du nuage, ce qui revient à écrire

$$y_0 = \bar{y} - (A_1\bar{x}_1 + A_2\bar{x}_2 + \dots + A_k\bar{x}_k)$$

les $\bar{y}, \bar{x}_1, \bar{x}_2, \dots, \bar{x}_k$ étant les valeurs moyennes précédemment calculées.

2. La deuxième méthode évite de centrer les variables grâce à un artifice qui consiste à adjoindre une colonne de 1 à gauche de la matrice X non centrée qui devient ainsi une matrice de dimensions $(n, k + 1)$. Le produit $X'X$ est alors une matrice carrée symétrique de dimensions $(k + 1, k + 1)$. Le produit $X'Y$ et le résultat A sont alors tous les deux de dimensions $(k + 1, 1)$ et le premier coefficient du vecteur A est le terme constant y_0 .

Cette deuxième méthode paraît plus simple que la première dans la mesure où elle évite un calcul supplémentaire pour trouver y_0 mais en réalité le temps gagné est la plupart du temps plus qu'entièrement compensé par le fait que l'ordinateur manipule des matrices d'ordre plus élevé. Par ailleurs, on augmente la précision générale du calcul en utilisant de petits chiffres (différences par rapport aux valeurs moyennes) et on tend à la diminuer en raisonnant sur des valeurs non centrées surtout dans la mesure où elles sont voisines les unes des autres. Pour ces raisons, on recommande vivement la première méthode.

Le coefficient de corrélation multiple se calcule comme suit :

$$R = \sqrt{1 - \frac{SCR}{\sum_{i=1}^n (y_i - \bar{y})^2}}$$

où SCR est la somme des carrés des résidus. En comparant chaque coefficient avec son écart-type, on obtient des renseignements intéressants. Si un coefficient est très grand par rapport à son écart-type, c'est un très bon coefficient et la variable correspondante est importante dans la corrélation. Dans le cas contraire, on peut avoir de sérieux doutes et il convient d'effectuer le test F qu'on va maintenant décrire à propos de la régression pas à pas.

2.5 Régression pas à pas

Il arrive dans certaines cas que les variables qu'on peut soupçonner d'avoir une influence sur Y sont extrêmement nombreuses et qui plus est, il est fort possible que certaines soient corrélées entre elles, de telle sorte qu'en les prenant ensemble, on fait en quelque sorte double emploi : il y a redondance. Il est alors indiqué de choisir les variables une par une en commençant par les plus significatives, en s'arrêtant à un seuil de signification donné au-delà duquel l'addition d'une variable supplémentaire n'apporte à peu près rien. C'est ce qu'on appelle la méthode pas à pas (stepwise en anglais) dont les étapes sont les suivantes :

1. On pratique une régression simple avec chacune des variables candidates et on retient comme première variable celle qui donne le coefficient R le plus élevé (où le SCR le plus petit, ce qui revient exactement au même).
2. On fait une régression double avec la première variable retenue et toutes les variables restantes. La encore, on choisit celle qui donne le SCR minimum ...
3. Et ainsi de suite.

Chacune de ces étapes diminue évidemment le SCR . On peut donc noter à chaque étape la diminution ΔSCR qu'elle permet d'obtenir et former la quantité :

$$F = \frac{\Delta SCR}{S^2} \quad \text{où} \quad S^2 = \frac{SCR}{n - k - 1}$$

Cette quantité F est comparée au F d'une table de Fisher pour 1 et $(n - k - 1)$ degrés de liberté et on s'arrête quand ce test devient négatif (F calculé $< F$ de la table).

Un raffinement supplémentaire de la méthode pas à pas consiste, à chaque étape, à réexaminer le cas des variables antérieures. Il se peut en effet qu'en raison des corrélations mutuelles, l'addition de la dernière variable rende inutile la présence d'une des précédentes X_j mais on ne peut le savoir qu'en calculant le F qu'on aurait obtenu en ajoutant X_j pour avoir le ΔSCR qui est dû au fait qu'on l'ajoute en fin de liste. On est ainsi amené à faire un certain nombre de régressions rétroactives d'ordre inférieur pour en avoir le cœur net. On arrive par cette méthode au meilleur choix possible avec un minimum de variables.

CHAPITRE 3

ANALYSE DES VARIANCES

3.1 Introduction

L'ANOVA est une des méthodes relativement anciennes de l'AD. Elle ne fait appel à aucun calcul matriciel et se présente simplement comme une application du théorème d'Huygens et du test de Fisher. Pour ce type d'analyse, la variable à expliquer est métrique alors que les variables explicatives sont nominales (c'est à dire appartenant à des catégories).

L'ANOVA consiste à vérifier l'hypothèse nulle, notée H_0 , qui signifie que les moyennes de plusieurs populations supposées normales et de même variance sont identiques.

Il existe plusieurs types d'ANOVA :

- ANOVA à un facteur
- ANOVA à deux facteurs sans interaction
- ANOVA à deux facteurs avec interaction
- ANOVA à deux facteurs hiérarchiques.

3.2 ANOVA à un facteur

3.2.1 Objectif

Etant donné k échantillons aléatoires simples et indépendants les uns des autres, ce type d'ANOVA cherche à vérifier l'hypothèse d'égalité des moyennes :

$$H_0 : m_1 = m_2 = \dots = m_k$$

où m_i est la moyenne de l'échantillon i .

3.2.2 Démarche : décomposition de la variance totale

Les moyennes des k échantillons et la moyenne générale de l'ensemble des observations permettent de définir deux types de variation :

- les écarts entre les différents échantillons (variance interclasse ou variance factorielle),
- les écarts existant à l'intérieur des échantillons (variance intra-classe ou variance résiduelle).

$$\begin{aligned}
\sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x})^2 &= \sum_{i=1}^k \sum_{j=1}^{n_i} (x_{ij} - \bar{x}_i)^2 + \sum_{i=1}^k n_i (\bar{x}_i - \bar{x})^2 \\
\begin{matrix} SST \\ DL \\ n-1 \end{matrix} &= \begin{matrix} SSE \\ n-k \end{matrix} + \begin{matrix} SSA \\ k-1 \end{matrix}
\end{aligned}$$

Le rapport de la variance factorielle à la variance résiduelle est une mesure observée du degré d'acceptation de l'hypothèse nulle. La valeur élevée de ce rapport correspond au rejet de l'hypothèse nulle. On évalue alors les rapports :

$$\frac{SST}{n-1} \quad \frac{SSE}{n-k} = s_e^2 \quad \frac{SSA}{k-1} = s_a^2$$

On compare le rapport $F_e = \frac{s_a^2}{s_e^2}$ au coefficient de Fisher théorique $F_{th} = F_{\alpha, k-1, n-k}$ pour la valeur de l'hypothèse nulle :

$$H_0 : F_e \leq F_{th}$$

3.2.3 Présentation des résultats : Tableau d'ANOVA

Source de variance	DL	Somme des carrés	carrés moyens	F
Factorielle	$k-1$	SSA	$\frac{SSA}{k-1} = s_a^2$	$F_e = \frac{s_a^2}{s_e^2}$
Résiduelle	$n-k$	SSE	$\frac{SSE}{n-k} = s_e^2$	
Total	$n-1$			

3.2.4 Exemple

On veut vérifier l'influence du facteur SONDE sur 3 échantillons :

Sonde 1	46	45	53	43	
Sonde 2	40	41	31		
Sonde 3	37	39	42	44	40

Dresser le tableau d'ANOVA et évaluer l'hypothèse nulle aux seuils de 5% et 1%.

3.3 ANOVA à deux facteurs sans interaction

Le principe de l'ANOVA à un facteur consiste à diviser la variance totale en deux composantes. Cette façon de procéder peut être étendue à 2 facteurs : la variance totale étant alors divisée en plus de 2 composantes, l'une résiduelle et les autres liées aux 2 facteurs.

Les deux facteurs considérés peuvent être sans interaction, avec interaction ou hiérarchiques.

3.3.1 Objectif

Il s'agit de vérifier indépendamment les influences des deux facteurs sur les observations.

3.3.2 Démarche : décomposition de la variance totale

Normalement, la variance totale se décompose en 4 variances :

$$SST = SSA + SSB + SSAB + SSE$$

où SSA est la variation due au premier facteur, SSB est celle due au deuxième facteur, $SSAB$ est celle due à l'interaction des deux facteurs et SSE est la variance résiduelle. Mais on suppose dans ce type d'ANOVA que l'interaction est nulle et ainsi $SSAB = 0$.

3.3.3 Organisation des calculs et présentation des résultats

On suppose que nous avons k modalités du facteur A et l modalités du facteur B , avec une observation pour chaque intersection.

	FACTEUR B					
		1	2	3	...	l
	1	x_{11}	x_{12}	x_{13}	$\cdots$	x_{1l}
	2	x_{21}	x_{22}	x_{23}	$\cdots$	x_{2l}
FACTEUR A	3	x_{31}	x_{32}	x_{33}	$\cdots$	x_{3l}
	$\vdots$	$\vdots$	$\vdots$	$\vdots$	$\ddots$	$\vdots$
	k	x_{k1}	x_{k2}	x_{k3}	$\cdots$	x_{kl}

L'effectif total des observations est $N = k.l$

Soit $G = \sum_{i=1}^k \sum_{j=1}^l x_{ij}$ la somme totale des observations, alors la moyenne générale est

$$\bar{x}_{..} = \frac{G}{N}.$$

La variance totale $SST = \sum_{i=1}^k \sum_{j=1}^l (x_{ij} - \bar{x})^2$ peut être décomposée en :

$$SSA = \sum_{i=1}^k l(\bar{x}_{i.} - \bar{x}_{..})^2 \quad SSB = \sum_{j=1}^l k(\bar{x}_{.j} - \bar{x}_{..})^2$$

$$SSE = SST - SSA - SSB$$

Le tableau d'ANOVA est dressé comme suit :

Source de variance	DL	Somme des carrés	carrés moyens	F
Factorielle A	$k - 1$	SSA	$\frac{SSA}{k - 1} = s_a^2$	$F_{ea} = \frac{s_a^2}{s_e^2}$
Factorielle B	$l - 1$	SSB	$\frac{SSB}{l - 1} = s_b^2$	$F_{eb} = \frac{s_b^2}{s_e^2}$
Résiduelle	$(k - 1)(l - 1)$	SSE	$\frac{SSE}{(k - 1)(l - 1)} = s_e^2$	
Total	$kl - 1$			

La vérification des hypothèses H_{0A} et H_{0B} se fait indépendamment pour les deux facteurs.

3.3.4 Exemple

3.4 ANOVA à deux facteurs avec interaction

3.4.1 Objectif

Répondre aux deux questions :

- Est-ce qu'il y a vraiment une interaction entre les deux facteurs ?
- Les modalités ont-elles des moyennes identiques vis-à-vis de chacun des facteurs ? (Hypothèses nulles)

3.4.2 Démarche

Cette fois, il faut considérer dans la décomposition de la variance totale la part de variance due à l'interaction des facteurs (ie $SSAB \neq 0$).

3.4.3 Organisation des calculs et présentation des résultats

On suppose que nous avons k modalités du facteur A , l modalités du facteur B et un nombre fixe et identique s d'observations dans chaque intersection.

L'effectif total d'observations est $N = k.l.s$. Soit $G = \sum_{i=1}^k \sum_{j=1}^l \sum_{r=1}^s x_{ijr}$ la somme totale des observations.

La variance totale $SST = \sum_{i=1}^k \sum_{j=1}^l \sum_{r=1}^s x_{ijr}^2 - \frac{G^2}{N}$ peut être décomposée en :

$$SSA = \sum_{i=1}^k \frac{T_{i..}^2}{ls} - \frac{G^2}{N}$$

$$SSB = \sum_{j=1}^l \frac{T_{.j.}^2}{ks} - \frac{G^2}{N}$$

$$SSAB = \left(\sum_{i=1}^k \sum_{j=1}^l \frac{T_{ij.}^2}{s} - \frac{G^2}{N} \right) - SSA - SSB$$

$$SSE = SST - SSA - SSB - SSAB$$

Le tableau d'ANOVA est dressé comme suit :

Source de variance	DL	Somme des carrés	carrés moyens	F
Factorielle A	$k - 1$	SSA	$\frac{SSA}{k-1} = s_a^2$	$F_{eab} = \frac{s_{ab}^2}{s_e^2}$
Factorielle B	$l - 1$	SSB	$\frac{SSB}{l-1} = s_b^2$	
Interaction	$(k-1)(l-1)$	$SSAB$	$\frac{SSAB}{(k-1)(l-1)} = s_{ab}^2$	
Résiduelle	$kl(s-1)$	SSE	$\frac{SSE}{kl(s-1)} = s_e^2$	

L'existence de l'interaction est vérifiée par la comparaison de F_{eab} à $F_{\alpha, (k-1)(l-1), kl(s-1)}$.

Dans le cas où l'interaction existe, on regroupe la variance due à l'erreur et celle due à l'interaction pour vérifier les hypothèses nulles sur les facteurs. Sinon, on néglige la variance due à l'interaction et on utilise celle due à l'erreur.

3.4.4 Exemple

3.5 ANOVA à deux facteurs hiérarchiques

Ce type d'ANOVA est de même type que celle à deux facteurs avec interaction. La seule différence réside sur le fait que l'évaluation des hypothèses sur le premier facteur est effectuée à partir de la variance due au second facteur au lieu d'utiliser la variance due à l'erreur.

$$F_{ea} = \frac{s_a^2}{s_b^2} \quad F_{eb} = \frac{s_b^2}{s_e^2}$$

CHAPITRE 4

ANALYSE FACTORIELLE D'UN NUAGE DE POINTS QUELCONQUE

Toutes les méthodes d'analyse factorielle comporte une étape que l'on peut décrire ainsi : étant donné l'espace vectoriel $\mathbb{R}^k$ dans lequel se situe un nuage de N points muni chacun d'une masse dans lequel on définit une *métrique*, calculer l'inertie totale de ce nuage de points, déterminer ses axes d'inertie, repérer les points dans la base formée par les axes d'inertie.

□ **Les entrées** d'une analyse factorielle sont dans tous les cas :

- ★ l'espace,
- ★ les points,
- ★ les masses affectées aux points,
- ★ la métrique.

□ **Les sorties** d'une analyse factorielle sont :

- ★ les axes d'inertie,
- ★ les coordonnées sur ces axes,
- ★ diverses indications d'aide à l'interprétation.

D'une analyse factorielle à une autre, seules varient les *entrées*, les définitions des points, des masses et de la métrique diffèrent selon que l'on considère une *Analyse Factorielle de Correspondance* (AFC), une *Analyse en Composantes Principales* (ACP) ou une *Analyse Factorielle Discriminante* (AFD). L'essentiel de la démarche est commun à toutes les méthodes.

4.1 Matrice d'inertie d'un nuage de points


Considérons un espace $\mathbb{R}^k$ dans lequel on situe N points X^i repérés par leurs coordonnées $(x_{ij}, \quad i = \overline{1, N}, \quad j = \overline{1, k})$. Chaque point X^i étant muni d'une masse m_i . On appellera nuage de points cet ensemble de points muni de masse et on note $\mathcal{N}(I)$.

Supposons que l'espace est muni de la métrique euclidienne canonique. On appelle **inertie** de $\mathcal{N}(I)$ par rapport au point P l'expression :

$$In_P = \sum_{i=1}^N m_i \|X^i - P\|^2$$

En pratique, le point P sera, selon les applications, placé soit à l'origine, soit au centre de gravité du nuage (centrage).

Chaque direction de $\mathbb{R}^k$ peut être repérée par un vecteur unitaire U de coordonnées u_j . On appelle *inertie par rapport au point P expliquée par la direction U* l'inertie des points Z^i projection orthogonale des X^i sous le vecteur U passant par P , si l'on associe à chaque Z^i la masse m_i



$$In_P(U) = \sum_{i=1}^N m_i \|Z^i - P\|^2$$

Si P est l'origine, on a alors :

$$In_P(U) = \sum_{i=1}^N m_i \|Z^i\|^2$$

Avec $\|Z^i\|^2 = (X^{i'}U)^2$
 Comme $X^{i'}U = \sum_j x_{ij}u_j$
 Alors

$$\|Z^i\|^2 = \sum_{jj'} x_{ij}x_{ij'}u_ju_{j'}$$

Soit $X'X$ la matrice (k, k) de termes courants $x_{ij}x_{ij'}$, on peut donc écrire :

$$(X^{i'}U)^2 = U'X'XU = U'(\sum_i m_i X^{i'}X^i)U = U'VU = In_P(U)$$

où V est une matrice carrée à k lignes et k colonnes de terme général

$$v_{jj'} = \sum_i x_{ij}x_{ij'}$$

Si on pose B la matrice à N lignes et k colonnes de terme général $b_{ij} = x_{ij}\sqrt{m_i}$, on vérifie que $V = B'B$, V est une matrice symétrique car $v_{jj'} = v_{j'j}$. Elle est donc diagonalisable et de valeurs propres réelles. On peut constituer une base orthonormée avec les vecteurs propres de V .

Classons les vecteurs propres de V par ordre décroissant. $\lambda_1 > \lambda_2 > \dots > \lambda_k$. Les valeurs propres d'une matrice d'inertie sont toutes positives ou nulles. En effet, l'inertie expliquée par le vecteur propre U_α associé à la valeur propre λ_α est $In(U_\alpha) = U_\alpha'VU_\alpha = \lambda_\alpha U_\alpha^2 = \lambda_\alpha$ et par construction, une inertie ne peut pas être négative.

4.2 Recherche du premier axe factoriel

Il s'agit de la direction de l'espace qui rend maximum l'expression $I_n(U)$. On trouve cette direction par la méthode de *Lagrange* : trouver la direction U qui maximise $U'VU$ sous la contrainte $U'U = 1$. On doit donc chercher les extrema de :

$$L = U'VU - \lambda(U'U - 1) \quad (\text{Lagrangien})$$

$$\frac{\partial L}{\partial U} = 0 \Rightarrow 2(VU - \lambda U) = 0 \Rightarrow VU = \lambda U$$


Le premier axe factoriel est donc forcément l'un des vecteurs propres de V . Le multiplicateur de Lagrange est égal à la valeur propre associée à ce vecteur. Ce premier axe est le vecteur propre U_1 correspondant à λ_1 , la plus grande valeur propre de V . L'inertie expliquée par cet axe factoriel est λ_1 .

4.2.1 Recherche des sous-espaces expliquant la plus grande inertie

Prolongeons le problème en considérant p vecteurs $U^1, U^2, \dots, U^p$ avec $p < k$. L'inertie expliquée par ces p vecteurs est

$$I_n(U^1, U^2, \dots, U^p) = \sum_{i=1}^N \|Z^i\|^2$$

où Z^i est la projection de X^i sur ce sous-espace.



$$\|Z^i\| = \sum_{r=1}^p (X^{i'} U^r)^2$$

$$I_n(U^1, U^2, \dots, U^p) = \sum_{i=1}^n m_i \sum_{r=1}^p (X^{i'} U^r)^2 = \sum_{r=1}^p U^{r'} V U^r$$

On cherche alors la famille de p vecteurs qui maximise $I_n(U^1, U^2, \dots, U^p)$ sous la contrainte $U^{r'} U^r = 1$

Le Lagrangien s'écrit :

$$L = \sum_r U^{r'} V U^r - \lambda_r (U^{r'} U^r - 1)$$

$$\frac{\partial L}{\partial U^r} = 2(V U^r - \lambda U^r) = 0 \Rightarrow V U^r = \lambda_r U^r$$

U^r est donc vecteur propre de V

$\sum_r U^{r'} V U^r = \sum_r \lambda_r$ est l'inertie expliquée par $(U^1, U^2, \dots, U^p)$

Les sous-espaces à p dimensions qui explique la plus grande inertie contient les p premiers vecteurs propres $U_1, U_2, \dots, U_p$ de V . L'inertie expliquée par ce sous-espace est la somme des valeurs propres correspondant à ces vecteurs propres.

Remarques

- ① Si $p = k$, l'inertie expliquée par $(U_1, U_2, \dots, U_p)$ devient l'inertie expliquée par l'espace tout entier

$$I_n(I) = \sum_{\alpha}^k \lambda_{\alpha}$$

- ② L'inertie du nuage est égale à la somme des vecteurs propres de V c'est à dire à la *trace* de V .

- ③ La part d'inertie totale expliquée par l'axe factoriel de rang α est :

$$\tau_{\alpha} = \frac{\lambda_{\alpha}}{I_n(I)} = \frac{\lambda_{\alpha}}{\sum_{r=1}^k \lambda_r}$$

- ④ La part d'inertie totale expliquée par le sous-espace défini par $U_1, U_2, \dots, U_p$ est

$$\sum_{\alpha=1}^p \tau_{\alpha}$$

- ⑤ Lorsqu'on procède à l'analyse factorielle d'un nuage à partir de son centre de gravité (AFC et ACP), on peut dire que les axes factoriels sont les directions le long desquelles on conserve la meilleure représentation des distances.

4.3 Récapitulation de la démarche d'une analyse factorielle

- ❶ Calcul de la matrice d'inertie V (métrique)
- ❷ Recherche des axes factoriels et des valeurs propres de V qui leurs sont associées : cette opération est la diagonalisation de la matrice V . Le résultat de cette recherche est la suite ordonnée des valeurs propres de V et des vecteurs propres qui leurs sont associés.
- ❸ Calcul des coordonnées des points X^i sur les axes factoriels, elles sont obtenues par :

$$F_{\alpha}(i) = U_{\alpha}' X^i = \sum_j u_{\alpha j} x_{ij}$$

- ❹ Représentation graphique : l'analyse factorielle permet de voir sur des graphiques, plans accessibles à notre perception, les nuages de points dans un espace de dimension $< k$.

4.4 QUELQUES AIDES A L'INTERPRETATION

- ① λ_α est l'inertie expliquée par l'axe U_α . Il est facile de voir que :

$$\lambda_\alpha = \sum_i m_i F_\alpha^2(i)$$

Nous pouvons donc mesurer dans l'inertie expliquée par U_α la contribution relative du point i :

$$CTR_\alpha(i) = \frac{m_i F_\alpha^2(i)}{\lambda_\alpha}$$

Cette expression est très importante car elle permet de classer les points X^i selon le rôle plus ou moins grand qu'ils ont joué dans la détermination de U_α .

- ② Soit θ l'angle de X^i avec U_α , alors $\cos^2 \theta$ mesure la qualité de représentation de i par sa projection sur l'axe U_α

$$\cos^2 \theta = \cos_\alpha^2(i) = \frac{F_\alpha^2(i)}{\|X^i - P\|^2}$$

La qualité de représentation du point i par le sous-espace à p dimensions formé des p premiers axes factoriels est mesurée par :

$$QLT_p(i) = \sum_{\alpha=1}^p \cos_\alpha^2(i)$$

- ③ La part d'inertie qui vient du point i dans l'inertie totale est :

$$CONTR(i) = \frac{m_i \|X^i - P\|^2}{I_{n_P}(i)}$$

Les points qui ont de faibles contributions à l'inertie totale sont, soit des points très légers, soit des points très proches de P . On améliore parfois la clarté de l'Analyse Factorielle en annulant la masse attribuée à ces points. Dotés d'une masse nulle, ils n'interviennent plus dans le positionnement des axes ; par contre leur image figure sur les projections graphiques.

- ④ Si Z^i est la projection de X^i sur le sous espace à p dimensions, on appelle ECART RELATIF de X^i au sous espace des p premiers axes la quantité :

$$ECART_p(i) = \frac{m_i \|X^i - Z^i\|^2}{\sum_i m_i \|X^i - Z^i\|^2}$$

Cet indicateur permet de repérer les points mal représentés par l'espace à p dimensions d'une façon plus précise que ne le permet l'indicateur QLT

CHAPITRE 5

ANALYSE EN COMPOSANTES PRINCIPALES (ACP)

L'ACP est la plus ancienne des méthodes d'analyse des données (mise au point par Hotelling en 1933). Elle est fondée de double analyse d'un nuage de points et de double projection sur les axes factoriels.

5.1 Choix de la métrique

Deux options sont classiques :

la métrique canonique : dans ce cas, les relations considérées entre les variables sont mesurées par les *covariances* ; on parle d'**ACP CANONIQUE** ;

la métrique normée : dans ce cas, les relations considérées entre les variables sont mesurées par les *coefficients de corrélation* ; on parle d'**ACP NORMÉE**

La covariance est un paramètre qui dépend des unités choisies pour mesurer les variables, cela peut créer des difficultés lorsque ces unités sont hétérogènes et l'on a tout l'intérêt si cela est le cas à effectuer une ACP normée.

Exemple : Considérons trois individus dont on a mesuré la taille et le poids :

	Taille(m)	Poids(Kg)
1	1,7	60
2	1,7	70
3	1,6	65

❶ Cas de la métrique canonique

Les distances au sens de cette métrique, entre les trois individus sont :

$$d^2(1, 2) = 100$$

$$d^2(1, 3) = 25,01$$

On a donc $d^2(1, 3) < d^2(1, 2)$. Changeons une unité, la taille est mesurée en cm et le poids reste en Kg.

$$d^2(1, 2) = 100$$

$$d^2(1, 3) = 125$$

L'ordre des distances est donc inversé : $d^2(1, 3) > d^2(1, 2)$

❷ Cas de la métrique normée

Les distances sont indépendantes des unités et on a

$$d^2(1, 2) = 6 \quad d^2(1, 3) = 6$$

5.2 Analyse du nuage des individus

Considérons N individus sur lesquels on observe k variables.

Soit k_{ij} la mesure des variables j sur l'individu i .

Soit le nuage *centré et réduit* formé par les points :

$$x_{ij} = \frac{k_{ij} - \bar{k}_j}{\sigma_j}$$

Cette transformation permet d'éliminer l'effet arbitraire dû au choix des unités de mesure.

Il s'agit maintenant de procéder à l'analyse factorielle du nuage, nous le ferons à partir de son centre de gravité. L'Analyse Factorielle d'un tel nuage nécessite que l'on diagonalise la matrice des variances V .

Reste à identifier les valeurs propres et vecteurs propres de V , et on a à projeter les points X^i sur ces vecteurs propres. On pourra alors visualiser aisément le nuage par projection sur les plans définis par des couples de vecteurs propres. La proximité des points X^i et $X^{i'}$ signifie que les valeurs k_{ij} et $k_{i'j}$ sont proches pour tous les j .

5.3 Analyse du nuage des variables

Nous associons à chaque variable j un point Y^j de $\mathbb{R}^N$ et dont la i ème coordonnée est :

$$y_{ij} = \frac{1}{\sqrt{N}} x_{ij} = \frac{k_{ij} - \bar{k}_j}{\sigma_j \sqrt{N}}$$

Il est important de bien interpréter la construction géométrique du nuage des variables fournies par l'ACP.

Considérons dans $\mathbb{R}^N$ le point P^j dont la i ème coordonnée est k_{ij} et le point $\bar{P}^j$ dont les coordonnées sont égales à $\bar{k}_j$. Il est clair que :

$$\sigma_j^2 = \frac{1}{N} \|P^j - \bar{P}^j\|^2 \quad \text{d'où} \quad Y^j = \frac{P^j - \bar{P}^j}{\|P^j - \bar{P}^j\|}$$

Y^j s'obtient donc à partir de P^j par la succession de deux opérations :

- ✓ projection sur le sous-espace à $N - 1$ dimensions orthogonal au vecteur dont toutes les composantes sont égales à 1 ;
- ✓ projection de centre O sur la sphère de centre O et de rayon 1.

Toutes les Y^j sont donc situés sur la sphère (O,1) et dans le sous espace orthogonal au vecteur (1,1,...,1). Le coefficient de corrélation entre les variables j et j' est :

$$\rho_{jj'} = \frac{\text{cov}(j, j')}{\sigma_j \sigma_{j'}}$$

On remarque que $\rho_{jj'} = Y^{j'} Y^j$.

Conclusion : Le nuage des points variables doit être interprété en terme de corrélation entre les variables.

5.4 Interprétation d'une ACP

On peut éditer l'image des projections de $\mathcal{N}(I)$ et de $\mathcal{N}(J)$ sur des plans formés par des couples d'axes factoriels. Il est instructif de superposer sur le même graphique l'image de deux nuages sur ces couples d'axes associés car la disposition des projections des points variables permet d'interpréter le nuage des points individus.

Remarque : L'image de $\mathcal{N}(I)$ est forcément centré sur l'origine comme $\mathcal{N}(I)$ lui-même. Par contre, il n'en est pas de même de $\mathcal{N}(J)$: il peut se produire que tous les points variables soient situés sur un graphique d'un même côté de l'origine.

Pour interpréter la relation qui existe entre les projections de $\mathcal{N}(I)$ et de $\mathcal{N}(J)$, il faut définir le coefficient de corrélation $\rho(U_\alpha, j)$ entre l'axe factoriel U_α et la variable j :

$$\begin{aligned}\rho(U_\alpha, j) &= \frac{\frac{1}{N}F_\alpha(i)(k_{ij} - \bar{k}_j)}{\sigma_j \sqrt{\frac{\lambda_\alpha}{N}}} \\ &= G_\alpha(j) \\ &= u_{\alpha_j} \sqrt{\frac{\lambda_\alpha}{N}}\end{aligned}$$

La coordonnée de Y^j sur l'axe factoriel U_α est égale au coefficient de corrélation de la variable j avec cet axe.

Supposons par exemple que $G_\alpha(j) = 1$. Cela veut dire qu'il existe entre les $F_\alpha(i)$ et les k_{ij} une relation linéaire du type :


$$F_\alpha(i) = a(k_{ij} - \bar{k}_j) \text{ avec } a \neq 0.$$

On peut directement interpréter le facteur $F_\alpha(i)$ comme un classement des individus le long de l'axe α , dans l'ordre des valeurs croissantes de la variable j : $F_\alpha(i)$ est proportionnel à l'écart entre la moyenne de j et la valeur de cette variable constatée sur l'individu i .

- ✖ Si $G_\alpha(j) = -1$, les individus sont classées sur l'axe α dans l'ordre des valeurs décroissantes de j .
- ✖ Si $G_\alpha(j) = 0$, il n'existe pas de relation linéaire entre les $F_\alpha(i)$ et les k_{ij} .

5.4.1 Interprétation du nuage des variables

On trouve assez souvent une configuration semblable à celle dessinée ci-dessous :



Sur l'axe 1, un groupe de variables figure avec des coordonnées proches de 1 (groupe I). Un autre groupe avec des coordonnées proches de -1 (groupe II) ; un groupe se trouve près du bord du cercle sans avoir des coordonnées fortes ni sur l'axe 1 ni sur l'axe 2 (groupe III) ; un groupe a des coordonnées relativement proches de -1 sur l'axe 2 (groupe IV) ; enfin quelques variables se projettent à l'intérieur du cercle.

On dira que l'axe 1 oppose les variables du groupe I à celles du groupe II. Chacun de ces groupes est formé de variables corrélées entre elles. Le groupe IV est formé de variables dont la corrélation avec les variables des groupes I et II est nulle, et qui ont une corrélation négative avec les variables du groupe III.

Le groupe IV est proche du bord du cercle (mais moins que les groupes I et II) dans la direction négative de l'axe 2.

5.4.2 Interprétation du nuage des individus

Une fois le nuage des variables interprété, on peut passer au nuage des individus. On peut remarquer que dans ce cas, on n'a pas vraiment besoin d'utiliser l'aide $CTR_\alpha(i)$:

$$CTR_\alpha(i) = \frac{F_\alpha^2(i)}{\sum_{i=1}^k F_\alpha^2(i)} \quad (m_i = 1)$$

Par contre, l'aide à l'interprétation fournie par les

$$\cos_\alpha^2(i) = \frac{F_\alpha^2(i)}{\|X^i - P\|^2}$$

est utile.

En effet, comme les points individus ne sont pas situés sur une sphère, on ne peut pas lire $\cos^2_\alpha(i)$ directement sur le graphique comme on pouvait le faire pour les points variables.

On sait que pour l'essentiel, l'axe 1 oppose les individus pour lesquels les variables du groupe I sont fortes et celles du groupe II sont faibles (à droite), aux individus pour lesquels c'est l'inverse (à gauche).

L'abscisse d'un individu sur l'axe 1 est même une mesure approchée correcte, à des transformations linéaires près, des variables de ces deux groupes.

Sur l'axe 2, on trouvera en haut des individus pour lesquelles les variables du groupe IV sont faibles, en bas des individus pour lesquels elles sont fortes, mais la relation entre $F_2(i)$ et ces variables est plus floue que celle qui existe sur l'axe 1.